

Eksplorasi Metode Segmentasi Optic Disc pada Citra Fundus

Imam Syahrizal, Izzun Nafis Ibadik, Pandega Abyan Zumarsyah
Departemen Teknik Elektro dan Teknologi Informasi
Universitas Gadjah Mada
Yogyakarta, Indonesia

imamsyahrizal@mail.ugm.ac.id, izzunnafis2018@mail.ugm.ac.id, pandegaabyan@mail.ugm.ac.id

Abstrak— Pengolahan citra fundus menjadi topik yang cukup populer sebagai cara untuk membantu menganalisis kondisi mata. Analisis ini dapat bermanfaat untuk deteksi beberapa penyakit mata seperti glaukoma dan retinopati. Pada penelitian ini, dilakukan eksplorasi beberapa metode untuk memperoleh hasil segmentasi terbaik. Metode pertama berkaitan dengan proses segmentasi berbasis region dengan algoritma GrowCut. Pada metode pertama ini juga memerlukan *preprocessing* dengan beberapa operasi morfologi. Metode kedua melakukan proses segmentasi dengan *thresholding* yang nilai *threshold*-nya diperoleh berdasarkan operasi turunan kedua dari data histogram derajat keabuan. Hasil *thresholding* ini kemudian digunakan sebagai nilai awal dari segmentasi berbasis region dengan algoritma GrabCut. Metode ketiga menggunakan algoritma Random Forest yang mana masukannya diperoleh dari hasil beberapa filter seperti sobel, prewitt, canny, dan beberapa filter lain. Dengan masukan tersebut, model dilatih untuk mengklasifikasikan piksel pada citra. Metode keempat menggunakan deep learning dengan arsitektur UNet dan model MobileNetV2. Berbagai metode tersebut dievaluasi dengan tiga dataset: dataset lokal, DRIONS-DB, dan RIM-ONE v3. Model UNet-MobileNetV2 memberikan hasil yang baik untuk ketiga dataset tersebut. Model Random Forest juga mampu melakukan segmentasi pada ketiga dataset, namun tidak menunjukkan hasil yang memuaskan pada dataset RIM-ONE v3. Sementara itu, metode 1 dan 2 mampu memberikan hasil yang cukup baik hanya saat diterapkan pada dataset lokal. Tanpa penyesuaian parameter, kedua metode ini sulit mengimbangi performa dari model UNet-MobileNetV2.

Kata kunci—*deep learning, fundus, Optic Disc, image processing, segmentasi.*

I. LATAR BELAKANG

A. Permasalahan

Fundus merupakan bagian mata yang letaknya berseberangan dengan lensa mata. Bagian ini menjadi bagian mata yang cukup banyak diteliti dari sisi analisis citra. Citra fundus ini akan mencakup bagian-bagian seperti macula, Optic Disc, Optic Cup, jaringan pembuluh darah, dan fovea.

Diagnosis penyakit melalui analisis citra fundus menjadi topik yang populer di komunitas pengolahan citra medis [1]. Retinopati diabetik, retinopati hipertensi, dan glaukoma merupakan beberapa penyakit yang memiliki fitur khusus dan dapat diidentifikasi melalui citra retina [2]. Retinopati diabetik merupakan salah satu penyebab utama kebutaan di dunia [3]. Sementara itu, retinopati hipertensi merupakan penyakit yang dapat mengakibatkan kehilangan penglihatan dan juga berkaitan erat dengan tekanan darah tinggi. Selain itu, glaukoma juga dapat mengakibatkan kebutaan.

Penyakit seperti glaukoma umumnya dapat dideteksi dengan meninjau ketidaknormalan dari Optic Disc baik secara

langsung maupun tidak langsung. Optic Disc merupakan bagian dari mata sebagai tempat keluarnya jaringan syaraf mata dan gerbang bagi jaringan pembuluh darah yang ada di mata. Area ini ditandai dengan bentuknya yang relatif bulat dan memiliki pencitraan yang relatif lebih terang dibandingkan area di sekitarnya. Pengecekan secara langsung bisa dilakukan oleh ahli oftalmologi menggunakan alat yang bernama *ophthalmoscope*. Untuk cara tidak langsung, ahli oftalmologi dapat melakukan pengecekan dan analisis pada citra fundus. Akan tetapi, pengecekan dengan cara tersebut akan menguras waktu yang tidak sedikit dan juga rawan akan *human error*. Cara seperti itu juga membutuhkan biaya yang cukup mahal. Untuk mengatasi hal itu, perancangan sistem deteksi glaukoma atau sistem segmentasi Optic Disc perlu dikembangkan [4].

B. Penelitian Terkait

Pembahasan mengenai Optic Disc sudah banyak dibahas dalam berbagai penelitian, baik itu untuk tujuan deteksi maupun untuk segmentasi. Terdapat berbagai macam metode yang sudah dikembangkan. Hoover dan Goldbaum [5] menggunakan algoritma Fuzzy Convergence untuk mendapatkan pusat asal jaringan pembuluh darah. Dengan mendapatkan titik asal pembuluh darah, titik tengah dari Optic Disc dapat dideteksi. Selain itu, Yasin Kaya [3], mencoba mencari titik tengah Optic Disc menggunakan Cuckoo Search Algorithm. Pencarian titik tengah Optic Disc dibagi menjadi tiga bagian, pertama *preprocessing* menggunakan Adaptive Histogram Equalization yang bertujuan untuk melakukan normalisasi iluminasi dan kontras pada citra. Selanjutnya, dilakukan deteksi Optic Disc menggunakan Structural Similarity Index Measurement (SSIM). Kemudian terakhir mencari titik tengah Optic Disc menggunakan CSA.

Untuk proses segmentasi, Laura J dkk [6] menggunakan metode *thresholding*, mereka membandingkan tiga jenis *thresholding*: Triangle Thresholding, Maximum Entropy Thresholding, dan Mean Peak Thresholding. Hasilnya, metode Triangle Thresholding adalah metode *thresholding* terbaik di antara ketiganya. Selain itu, dari pengujian, mereka mengetahui bahwa channel Green memberikan kontras yang paling baik. Kemudian Dulanji Lokuarachchi dkk [2] juga mencoba membandingkan penggunaan channel Green dan Red pada proses segmentasi Optic Disc. Dari pengujian mereka, didapatkan kesimpulan bahwa penggunaan kedua channel Red dan Green akan mendapatkan hasil yang lebih baik daripada hanya menggunakan salah satu channel saja. Proses segmentasi yang mereka lakukan juga memanfaatkan operasi Morphological Closing dan Morphological Dilation.

Kemudian, terdapat dua penelitian lain yang menggunakan channel Green dalam pengujiannya. Muhammad Abdullah dkk [7] melakukan pendeteksian titik tengah dan segmentasi Optic Disc menggunakan channel

Green. Mereka melakukan *preprocessing* dengan tujuan normalisasi tidak seragamnya kontras dan juga luminasi dari berbagai jenis citra. Selanjutnya, dilakukan deteksi area Optic Disc menggunakan Circular Hough Transform. Algoritma GrowCut digunakan untuk memisahkan antara *background* dengan Optic Disc. Sementara itu, Daniel Welfer dkk [8] menggunakan operasi matematika morfologi dalam deteksi dan segmentasi Optic Disc. Itu terdiri dari dua proses utama: (1) Deteksi lokasi dari Optic Disc menggunakan informasi dari *vascular tree*, (2) Penentuan batas Optic Disc menggunakan transformasi Watershed. Dataset yang mereka gunakan berasal dari dataset DRIVE dan DIARETDB1. Selanjutnya dari Welfer dkk [8], mereka melakukan pendeteksian dan segmentasi Optic Disc menggunakan LUV Color Space tepatnya pada channel L.

Jun Cheng dkk [9] melakukan segmentasi Optic Disc dan juga Optic Cup menggunakan metode Superpixel Classification. Selain itu ada juga yang menggunakan pendekatan deep learning seperti Syna Sreng dkk [4]. Tujuan dari penelitian mereka adalah melakukan segmentasi Optic Disc dan juga klasifikasi Glaukoma. Untuk proses segmentasi mereka menggunakan DeepLabv3+. DeepLabv3+ terdiri dari dua fase, yakni encoder dan decoder. Encoder digunakan untuk mengekstrak fitur-fitur dari citra fundus. Sementara decoder akan menghasilkan batas boundary dari Optic Disc. Kemudian dari boundary yang didapatkan dari decoder dapat dibuat sebuah mask yang merupakan area dari Optic Disc.

C. Tujuan

Tujuan pengujian kali ini adalah mengeksplorasi beberapa metode dan mengevaluasi metode terbaik dalam melakukan segmentasi Optic Disc pada citra fundus. Hasil segmentasi yang diperoleh dapat digunakan untuk proses analisis citra selanjutnya, seperti klasifikasi.

II. DATA DAN METODOLOGI

A. Data

Pada penelitian kali ini, digunakan tiga buah dataset citra fundus yang disertai dengan anotasi Optic Disc. Dataset pertama sudah tersedia sementara dua lainnya merupakan dataset publik yang dapat diakses secara bebas.

Dataset 1

Dataset pertama yang digunakan memiliki 100 citra fundus dengan resolusi yang cukup tinggi yaitu 3072×2048 piksel. Gambar 1 menunjukkan contoh citranya. Citra ini memiliki anotasi ground truth dalam bentuk matriks berformat mat. Ground truth tersebut mengandung informasi dari area Optic Disc dan juga Optic Cup.



Gambar 1 Citra fundus Dataset 1

Dataset 2 (DRIONS-DB)

Dataset ini terdiri atas 110 citra yang secara acak dipilih dari Ophthalmology Service di Miguel Servet Hospital, Saragossa (Spain). Citra disimpan dengan resolusi 600×400 piksel dalam format 8 bit. Gambar 2 menunjukkan contoh


citranya. Citra fundus dari dataset ini memiliki fitur-fitur penanda penyakit dari penderitanya. Sebanyak 23% merupakan citra dari penderita glaukoma dan 77% sisanya citra dari penderita hipertensi mata. Ground truth dianotasi oleh 2 ahli oftalmologi secara terpisah yang kemudian hasilnya dirata-rata dan dijadikan *gold standard*[9].



Gambar 2 Citra fundus dari Dataset 2 (DRIONS-DB)

Dataset 3 (RIM-ONE r3)

Dataset ketiga memiliki 159 citra fundus yang disusun dari data fundus milik Hospital Universitario de Canarias, Hospital Clínico San Carlos, dan Hospital Universitario Miguel Servet. Ketiganya merupakan rumah sakit asal Spanyol. Pada data ini, citra direpresentasikan sebagai citra stereo yang disusun horizontal. Gambar 3 menunjukkan contoh citranya. Anotasi dilakukan terhadap fitur Optic Disc sebelah kiri. Dua ahli oftalmologi melakukan segmentasi secara manual yang kemudian hasilnya dirata-rata dan dijadikan *gold standard*.



Gambar 3 Citra fundus dari Dataset 3 (RIM-ONE r3)

B. Metodologi

Metode 1

Metode ini merupakan modifikasi dari penelitian yang berjudul *Localization and Segmentation of Optic Disc in Retinal Images Using Circular Hough Transform and Grow-Cut Algorithm*. Pada penelitian asli, digunakan channel Green dari sistem RGB. Di sini, kami mencoba menggunakan channel Value dari sistem HSV. Gambar 4 berikut menunjukkan blok diagram alur metode yang digunakan



Gambar 4 Blok diagram implementasi metode 1

Pada tahap preprocessing citra fundus dikonversi dari ke color space HSV. Dari color space ini diambil nilai matriks pada channel Value.

Dari channel Value ini kemudian dilakukan operasi normalisasi, *adjustment*, dan *shade-correction*. Normalisasi dilakukan dengan operasi pengurangan antara citra yang dikenai operasi *opening* "Iopen" dengan estimasi citra latar "Ibg" yang diperoleh melalui operasi filter mean. Operasi *opening* dilakukan dengan kernel lingkaran berjari-jari 100 piksel sedangkan filter mean dilakukan dengan kernel berukuran 750×750 piksel. Selanjutnya, proses *adjustment* dilakukan dengan mengurangi citra ternormalisasi dengan nilai piksel terbanyak di citra ternormalisasi ditambah 0.5. *Shade-correction* dilakukan melalui operasi saturasi dengan batas 0 dan 1.


Tahap selanjutnya, citra melalui proses operasi *closing* untuk menghilangkan fitur pembuluh darah. Di sini, digunakan filter lingkaran berukuran 150×150 piksel. Dengan hilangnya fitur pembuluh darah, proses dilanjutkan dengan pendeteksian fitur Optic Disc. Deteksi Optic Disc dilakukan dengan mencari fitur lingkaran menggunakan Circular Hough Transform. Diasumsikan bahwa ukuran lingkaran memiliki kisaran radius antara 180 hingga 220 piksel. Lingkaran-lingkaran yang didapatkan kemudian dicari yang paling valid dan paling merepresentasikan posisi dari Optic Disc.

Di tahap terakhir, dilakukan proses segmentasi dengan melakukan pemisahan antara fitur background dengan Optic Disc menggunakan algoritma GrowCut. GrowCut melakukan pelabelan piksel berdasarkan konsep *cellular automata* [10]. Dengan deteksi Optic Disc yang telah dilakukan, kemudian ditentukan region yang sudah pasti masuk ke Optic Disc dan area yang pasti tidak masuk ke Optic Disc. Penentuan awal ini penting untuk algoritma GrowCut. Area yang tersisa kemudian akan ditentukan kategorinya melalui proses GrowCut. Proses ini dilakukan secara iteratif dengan memperhatikan kemiripan suatu piksel dengan piksel-piksel tetangga dan *strength* dari piksel tersebut. Piksel yang kategorinya sudah ditentukan di awal, memiliki *strength* = 1 dan tidak akan mengalami pergantian kategori.

Metode 2

Metode kedua yang kami gunakan adalah segmentasi menggunakan *thresholding*. Operasi *thresholding* dilakukan dengan asumsi bahwa fitur Optic Disc merupakan fitur paling terang dari keseluruhan citra fundus. Untuk segmentasi, digunakan channel Value dari sistem warna HSV. Nilai *threshold* diperoleh dengan melakukan operasi turunan kedua dari histogram intensitas pixel dari channel Value. Dari operasi ini kemudian ditentukan titik terbesar yang hasil turunan keduanya bernilai nol. Dilakukan pula proses optimasi dengan algoritma GrabCut dan Fit-Ellipse. Fit ellipse bertujuan untuk memperoleh bentuk segmentasi elips yang lebih halus. Sementara itu, algoritma GrabCut adalah metode segmentasi iteratif berbasis minimisasi energi [11]. Skema pengujian yang dilakukan dapat dilihat pada Gambar 5.

Untuk mempersiapkan algoritma GrabCut, dilakukan operasi erosi pada citra hasil *thresholding* dengan kernel lingkaran 150×150 . Hasilnya dapat dianggap sebagai bagian yang sudah pasti Optic Disc. Citra hasil *thresholding* tersebut juga dikenai operasi dilasi dengan kernel yang sama. Bagian luar dari hasil dilasi tersebut kemudian dianggap sebagai bagian yang pasti bukan Optic Disc. Seperti algoritma GrowCut, inisiasi seperti ini diperlukan sebelum menjalankan algoritma GrabCut. Gambar 5 menunjukkan skema pengujian yang dilakukan

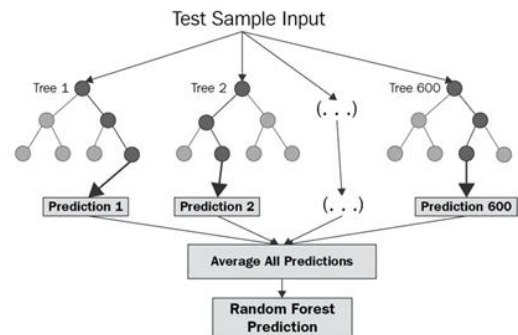


Gambar 5 Blok diagram metode 2

Terdapat empat buah skenario: (1) Citra hanya disegmentasi dengan *thresholding*, (2) Citra disegmentasi dengan *thresholding* dan dioptimalisasi dengan Fit-Ellipse, (3) Citra disegmentasi dengan *thresholding* dan GrabCut, serta (4) Citra disegmentasi dengan *thresholding* dan GrabCut kemudian dioptimalisasi dengan Fit-Ellipse.


Metode 3

Pengujian ketiga akan melakukan segmentasi dengan memanfaatkan klasifikasi dari Random Forest. Random Forest merupakan pengembangan dari Decision Tree. Decision Tree memiliki masalah pada *overfitting* dan kurangnya generalisasi. Random Forest hadir dengan menambahkan keacakan dalam melatih *tree* dan juga menggabungkan keluaran dari beberapa *tree* secara acak menjadi sebuah klasifikasi [12]. Gambar 6 merupakan ilustrasi bagaimana metode ini diimplementasikan



Gambar 6 Metode Random Forest

Pada pengujian ini, Random Forest digunakan untuk mengklasifikasikan setiap piksel menjadi dua kelas, yakni Optic Disc dan *background*. Proses segmentasi menggunakan Random Forest ini terdiri dari lima buah langkah yang terdapat pada Gambar 7.



Gambar 7 Blok diagram metode 3


Tahap awal adalah *preprocessing*, pada tahap ini citra akan dikonversi dari sistem RGB ke sistem HSV dan kemudian hanya akan digunakan channel Value nya saja. Tahap selanjutnya adalah mengekstrak fitur-fitur yang ada pada citra. Proses Ekstraksi fitur ini akan menggunakan beberapa filter : Gabor, Canny, Robert, Sobel, Scharr, Prewitt, Gaussian, dan Median. Setelah mendapatkan Fitur-fitur dari beberapa filter, data yang masih berbentuk gambar akan diubah menjadi data frame berdimensi satu. Selanjutnya akan dilakukan proses normalisasi yang akan menghasilkan data frame yang siap dilatih untuk membuat model klasifikasi Random Forest. Tahap keempat adalah membuat model klasifikasi dengan menggunakan Random Forest. Tahap terakhir adalah melakukan prediksi pada citra yang tidak digunakan sebelumnya. Tahap prediksi dimulai dengan melakukan ekstraksi fitur yang kemudian dilanjutkan proses klasifikasi setiap pikselnya.

Metode 4

Metode yang selanjutnya menggunakan deep learning dengan arsitektur UNet dan modelnya adalah MobileNetV2. UNet merupakan arsitektur yang memang didesain untuk segmentasi citra medis. Pada UNet, terdapat bagian enkoder dan dekoder. Enkoder melakukan *downsampling* pada citra sementara dekoder melakukan *upsampling*. [13]

Model yang digunakan adalah MobileNetV2 yang telah dilatih menggunakan dataset ImageNet. MobileNetV2 sendiri merupakan model ringan yang dapat digunakan di perangkat mobile. MobileNetV2 menggunakan *depthwise separable convolution* (Dwise) agar lebih efisien. [14] Gambar 8 menunjukkan skema dari model ini. Terlihat adanya Dwise dan *shortcut* yang dapat meringankan kinerja.

Konsep Dwise adalah dengan mengganti konvolusi biasa yang berat menjadi dua layer yang berisi konvolusi ringan. Layer pertama disebut *depthwise convolution* sementara yang kedua disebut *pointwise convolution*. Dengan menggunakan 3×3 Dwise, komputasi dari MobileNetV2 bisa sembilan kali lebih ringan dibanding konvolusi biasa tanpa perbedaan signifikan pada akurasi [15].



Gambar 8 Model MobileNetV2 [15]

Ringkasan Metode

- Metode 1: *Preprocessing* dilanjut dengan Circular Hough Transform dan diakhiri dengan GrowCut
- Metode 2.1.1: *Thresholding*
- Metode 2.1.2: *Thresholding* lalu dioptimasi dengan Fit-Ellipse
- Metode 2.2.1: *Thresholding* dilanjut dengan GrabCut
- Metode 2.2.2: *Thresholding* dilanjut dengan GrabCut lalu dioptimasi dengan Fit-Ellipse
- Metode 3: Random Forest Classifier untuk segmentasi
- Metode 4: *Deep learning* dengan arsitektur UNet dan model MobileNetV2

Parameter Pengukuran

Proses segmentasi yang dilakukan menghasilkan citra biner yang menandai piksel Optic Disc dan non Optic Disc. Hasil segmentasi ini akan dievaluasi dengan data ground truth yang dimiliki dan menghasilkan 4 buah parameter: True Positive (TP), True Negative (TN), False Positive (FP), dan

False Negative (FN). TP adalah keadaan ketika klasifier memprediksi piksel tersebut merupakan bagian dari Optic Disc dan pada ground truth juga merupakan bagian dari Optic Disc. Sementara itu, TN adalah keadaan ketika baik klasifier maupun ground truth mengidentifikasi piksel tersebut merupakan bagian dari non Optic Disc. FP terjadi ketika klasifier memprediksi piksel tersebut merupakan bagian dari Optic Disc, tetapi di ground truth piksel tersebut merupakan bagian dari non Optic Disc. FN terjadi ketika sistem memprediksi piksel tersebut non Optic Disc, tetapi ketika di ground truth merupakan piksel Optic Disc.

Untuk mengukur performa secara kuantitatif digunakan beberapa pengukuran yang ada pada Tabel I.

Tabel I Parameter pengukuran performa

Pengukuran	Deskripsi
ACC	$(TP + TN) / (TP + FP + TN + FN)$
PPV	$TP / (TP + FP)$
SN	$TP / (TP + FN)$
FDR	$FP / (FP + TP)$
Dice	$2 * TP / (2 * TP + FP + FN)$
Overlap	$TP / (TP + FP + FN)$

III. HASIL DAN ANALISIS

Dataset 1

Tabel II Performa pengujian dataset 1

	ACC	SP	SN	PPV	FDR	D	O
1	0.997	0.997	0.983	0.872	0.128	0.920	0.857
2.1.1	0.991	0.991	0.973	0.863	0.137	0.895	0.838
2.1.2	0.990	0.990	0.975	0.850	0.150	0.887	0.829
2.2.1	0.989	0.989	0.979	0.829	0.171	0.885	0.812
2.2.2	0.989	0.989	0.996	0.830	0.170	0.887	0.827
3	0.993	0.994	0.927	0.889	0.111	0.886	0.820
4	0.998	0.999	0.940	0.959	0.041	0.947	0.901

Dari Tabel II, dapat dilihat bahwa semua metode memberikan nilai akurasi dan spesifisitas yang tinggi untuk Dataset 1, bahkan semuanya lebih dari 98%. Metode 4 memberikan nilai yang tertinggi diikuti metode 3. Ini wajar saja mengingat keduanya menggunakan konsep learning.

Kemudian, nilai sensitivitasnya juga tinggi yaitu di atas 92%. Nilai sensitivitas yang tinggi ada di kelompok metode 2 yang menggunakan *thresholding*, GrabCut, dan Fit-Ellipse. Ini berarti, berbagai teknik pada metode 2 mampu meminimalkan False Negative.

Sementara itu, nilai PPV dan FDR yang didapatkan masih relatif rendah dibanding parameter lain. Perlu diketahui bahwa $FDR = 1 - PPV$ dengan nilai terbaik untuk PPV adalah 1 dan nilai terbaik untuk FDR adalah 0. Karena hasilnya secara umum kurang baik, kita dapat menyimpulkan bahwa hasil yang didapatkan masih mengandung beberapa False Positive. Pengecualiannya adalah pada metode 4 yang mana PPV nya mencapai 95.9%, jauh di atas metode lainnya.

Kemudian, untuk koefisien Dice yang mana ini banyak dipakai dalam segmentasi citra, seluruh metode memberikan

hasil di atas 88%. Metode 4 memberikan hasil terbaik dengan nilai 94.7% diikuti metode 1 dengan nilai 92.0%. Sementara itu, parameter overlap pada dasarnya mirip dengan koefisien Dice karena formulanya juga mirip.

Dari pengujian ini, dapat disimpulkan bahwa secara umum metode 4 yang menggunakan model UNet-MobileNetV2 memberikan performa terbaik dibanding metode lainnya. Selain itu, didapatkan bahwa pada metode 2, optimasi menggunakan GrabCut dan Fit-Ellipse tidak meningkatkan performa, bahkan terkadang justru memperburuk.

Dataset 2

Tabel III Performa pengujian dataset 2

	ACC	SP	SN	PPV	FDR	D	O
2.1.1	0.972	1.000	0.132	0.980	0.020	0.219	0.131
2.1.2	0.972	1.000	0.153	0.981	0.019	0.248	0.151
3.1	0.979	0.992	0.605	0.828	0.172	0.665	0.496
3.2	0.953	0.958	0.820	0.660	0.340	0.668	0.510
4	0.996	0.997	0.963	0.878	0.122	0.917	0.848

Tabel III menunjukkan pengujian dari tiga metode menggunakan Dataset DRIONS-DB. Secara umum, dibandingkan pengujian pada Dataset 1, performanya jauh lebih buruk. Di satu sisi, ini karena metode yang ada dikembangkan untuk mengoptimasi Dataset 1. Di sisi lain, citra pada Dataset 2 ini secara visual memang lebih kompleks dibanding citra pada Dataset 1. Selain itu, penggunaan channel V pada tiga metode pertama hanya sesuai untuk citra pada Dataset 1 dan kurang sesuai untuk dua dataset lainnya.

Meski demikian, terlihat bahwa nilai untuk akurasi dan spesifisitas untuk semua metode tetap cukup tinggi, dengan nilai terendahnya di atas 95%. Sama dengan pengujian pada dataset 1, metode 4 menghasilkan nilai akurasi tertinggi dan diikuti dengan metode 3.1 yaitu model Random Forest dengan 20 citra latih.

Akan tetapi, Random Forest dengan citra latih sebanyak satu buah, yaitu pada metode 3.2, menghasilkan nilai akurasi terendah. Dari sini dapat dilihat bahwa penambahan citra latih untuk metode 3 akan meningkatkan nilai akurasi. Di sisi lain, metode 3.2 memiliki keunggulan pada nilai sensitivitas dan koefisien Dice.

Perolehan nilai spesifisitas tertinggi pada Dataset DRIONS-DB adalah metode 2 segmentasi menggunakan Threshold dengan perolehan 100% baik dengan maupun tanpa optimasi Fit-Ellipse.

Kemudian, nilai sensitivitas yang didapatkan kurang maksimal, bahkan hanya sebesar 13% untuk metode thresholding. Sensitivitas yang rendah menunjukkan banyaknya False Negative pada citra hasil segmentasi.

Sementara itu, untuk perolehan nilai PPV, hanya metode 2 menggunakan thresholding yang mampu mencapai 98%. Nilai PPV tinggi pada metode 2 ini menjadi semacam kompensasi dari nilai sensitivitas yang rendah.

Dataset 3

Tabel IV Performa pengujian dataset 3

	ACC	SP	SN	PPV	FDR	D	O
3	0.932	0.951	0.509	0.505	0.495	0.457	0.317
4	0.995	0.998	0.921	0.961	0.039	0.935	0.885

Tabel IV merupakan pengujian menggunakan Dataset RIM-ONE. Di pengujian ini hanya dua metode saja yang diuji, yaitu metode 3 dan metode 4. Dari Tabel IV, dapat dilihat bahwa metode 4 mengungguli metode 3 di semua parameter.

Metode 3 memberikan akurasi dan spesifitas yang tinggi, namun kurang baik untuk parameter lain. Ini karena metode 3 hanya menggunakan channel V dari citra yang mana hal ini kurang sesuai jika diterapkan untuk citra pada Dataset 3.

Diskusi

Dataset DRIONS-DB menjadi dataset yang lebih populer dibandingkan dengan dataset lain. Dari peninjauan yang dilakukan diperoleh perbandingan metode-metode yang pernah diteliti sebagai berikut.

Tabel V Perbandingan performa pada dataset DRIONS-DB

		ACC	SP	SN	PPV	FDR	DICE	OL
Abdullah et al 2016 [7]		0.955	0.997	0.851	0.997	0.051	0.910	0.851
Lokuarachchi et al 2019 [2]		0.973	-	-	-	-	-	-
Proposed	2.1.1	0.972	1.000	0.132	0.980	0.020	0.219	0.131
	2.1.2	0.972	1.000	0.153	0.981	0.019	0.248	0.151
	3.1	0.979	0.992	0.605	0.828	0.172	0.665	0.496
	3.2	0.953	0.958	0.820	0.660	0.340	0.668	0.510
	4	0.996	0.997	0.963	0.878	0.122	0.917	0.848

Dari Tabel 5, secara umum terlihat bahwa metode yang kami ajukan mampu unggul dalam hal akurasi dan spesifitas, tetapi kurang baik pada parameter yang lain. Metode 4 yang menggunakan model UNet-MobileNetV2 menjadi satu-satunya metode yang hasilnya dapat mengimbangi hasil dari Abdullah et al. Ini karena sebagaimana telah disampaikan, metode lainnya dioptimasi untuk Dataset 1 dan belum disesuaikan untuk Dataset DRIONS-DB ini. Mengingat performa setiap metode pada Dataset 1 cukup bagus, penyesuaian berbagai parameter pada tiga metode awal dapat meningkatkan performa mereka untuk Dataset DRIONS-DB.

IV. KESIMPULAN

Segmentasi Optic Disc dari citra fundus merupakan hal yang penting dilakukan dalam proses analisa citra lebih lanjut seperti klasifikasi. Pada pengujian kali ini kami mengeksplorasi dan mengevaluasi metode-metode segmentasi Optic Disc. Dari evaluasi didapatkan bahwa secara umum metode yang kami ajukan mampu unggul dalam akurasi dan spesifitas, tetapi kurang baik pada parameter lain. Selain itu, metode 4 yaitu deep learning dengan arsitektur UNet dan model MobileNetV2 merupakan metode terbaik dibandingkan dengan metode lainnya. Hal ini terlihat dimana metode 4 mampu beradaptasi dengan ketiga dataset. Sementara itu metode 1 & 2 hanya mampu memberikan hasil yang cukup baik pada dataset 1. Ini disebabkan optimisasi parameter memang hanya ditujukan pada dataset tersebut. Metode 3 mampu memberikan hasil yang baik pada dataset 1

dan 2 namun tidak mampu menyaingi hasil dari metode 4 terutama pada dataset 3.

DAFTAR PUSTAKA

- [1] H. Ullah, Z. Jan, R. J. Qureshi, and B. Shams, "Automated localization of Optic Disc in colour fundus images," *World Appl. Sci. J.*, vol. 28, no. 11, pp. 1579–1584, 2013, doi: 10.5829/idosi.wasj.2013.28.11.2077.
- [2] D. Lokuarachchi, L. Muthumal, T. D. Gamage, and K. Gunarathna, "Localization of the Optic Disc Using Red and Green Channels of the Retinal Images," *2019 Int. Conf. Adv. Comput. ICAC 2019*, pp. 261–266, 2019, doi: 10.1109/ICAC49085.2019.9103394.
- [3] Y. Kaya, "A novel method for Optic Disc detection in retinal images using the cuckoo search algorithm and structural similarity index," *Multimed. Tools Appl.*, vol. 79, no. 31–32, pp. 23387–23400, 2020, doi: 10.1007/s11042-020-09080-5.
- [4] S. Sreng, N. Maneerat, K. Hamamoto, and K. Y. Win, "Deep learning for Optic Disc segmentation and glaucoma diagnosis on retinal images," *Appl. Sci.*, vol. 10, no. 14, 2020, doi: 10.3390/app10144916.
- [5] A. Hoover and M. Goldbaum, "Locating the optic nerve in a retinal image using the fuzzy convergence of the blood vessels," *IEEE Trans. Med. Imaging*, vol. 22, no. 8, pp. 951–958, 2003, doi: 10.1109/TMI.2003.815900.
- [6] L. J. Uribe-Valencia and J. F. Martinez-Carballido, "Thesholding methods review for the location of the Optic Disc in retinal fundus color images," *2016 13th Int. Conf. Electr. Eng. Sci. Autom. Control. CCE 2016*, 2016, doi: 10.1109/ICEEE.2016.7751228.
- [7] M. Abdullah, M. M. Fraz, and S. A. Barman, "Localization and segmentation of Optic Disc in retinal images using circular Hough transform and grow-cut algorithm," *PeerJ*, vol. 2016, no. 5, pp. 1–22, 2016, doi: 10.7717/peerj.2003.
- [8] D. Welfer, J. Scharcanski, C. M. Kitamura, M. M. Dal Pizzol, L. W. B. Ludwig, and D. R. Marinho, "Segmentation of the optic disk in color eye fundus images using an adaptive morphological approach," *Comput. Biol. Med.*, vol. 40, no. 2, pp. 124–137, 2010, doi: 10.1016/j.compbiomed.2009.11.009.
- [9] J. Cheng *et al.*, "Supervoxel classification based Optic Disc and optic cup segmentation for glaucoma screening," *IEEE Trans. Med. Imaging*, vol. 32, no. 6, pp. 1019–1032, 2013, doi: 10.1109/TMI.2013.2247770.
- [10] E. J. Carmona, M. Rincón, J. García-Feijó, and J. M. Martínez-de-la-Casa, "Identification of the optic nerve head with genetic algorithms," *Artif. Intell. Med.*, vol. 43, no. 3, pp. 243–259, Jul. 2008, doi: 10.1016/j.artmed.2008.04.005.
- [11] V. Vezhnevets and V. Konouchine, "GrowCut-Interactive multi-label N-D image segmentation by cellular automata," *Graph. 2005 - Int. Conf. Comput. Graph. Vision, Proc.*, no. July, 2005.
- [12] C. Rother, V. Kolmogorov, and A. Blake, "GrabCut - Interactive foreground extraction using iterated graph cuts," *ACM SIGGRAPH 2004 Pap. SIGGRAPH 2004*, no. August 2004, pp. 309–314, 2004, doi: 10.1145/1186562.1015720.
- [13] F. Schroff, A. Criminisi, and A. Zisserman, "Object class segmentation using random forests," *BMVC 2008 - Proc. Br. Mach. Vis. Conf. 2008*, 2008, doi: 10.5244/C.22.54.
- [14] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L. C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, pp. 4510–4520, 2018, doi: 10.1109/CVPR.2018.00474.
- [15] A. Sarhan *et al.*, "Utilizing Transfer Learning and a Customized Loss Function for Optic Disc Segmentation from Retinal Images," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 12626 LNCS, pp. 687–703, 2021, doi: 10.1007/978-3-030-69541-5_41.

Tabel Pembagian Tugas Kelompok

No.	Nama Anggota	Tugas yang dikerjakan	Persentasi
1.	Imam Syahrizal	<ul style="list-style-type: none"> - Pengembangan metode 3 - Mempersiapkan laporan - Mempersiapkan presentasi - Pengolahan data hasil - Mempersiapkan dataset - Mempersiapkan refrensi paper 	<ul style="list-style-type: none"> - 100% - 33% - 33% - 100% - 20% - 100%
2.	Izzun Nafis Ibadik	<ul style="list-style-type: none"> - Mempersiapkan dataset - Mempersiapkn kode untuk evaluasi - Pengembangan metode 1 - Pengembangan metode 2 - Mempersiapkan laporan - Mempersiapkan presentasi 	<ul style="list-style-type: none"> - 80 % - 100 % - 70% - 100% - 33% - 33%
3.	Pandega Abyan Zumarsyah	<ul style="list-style-type: none"> - Pengembangan metode 1 - Pengembangan metode 4 - Mempersiapkan kode akhir - Mempersiapkan laporan - Mempersiapkan presentasi 	<ul style="list-style-type: none"> - 30% - 100% - 100% - 33% - 33%

NB:

1. Laporan dapat ditulis dalam bentuk bahasa indonesia atau bahasa inggris
2. Mohon sertakan source code pada saat mengumpulkan laporan untuk pengecekan hasil.